

Независимая валидация РядТерра / СберИндекс, задача 2

Дата проверки: 05.10.2026. Проверен локальный непубликованный сайт, отдельный PDF-отчёт и отдельная PPTX-презентация. Исходные вложения и 124 файла вложенного научного архива не изменены. Испытания выполнялись в копии; предложение исправления asof.py вынесено отдельно.

Направление	Вердикт
Соответствие заданию	Основная локальная структура соответствует: данные СберИндекса, 1/3/6/12, MAE, сравнение, русский отчёт, PDF и лендинг. Подача не завершена: отсутствует GitHub; инструкции и версии требуют исправлений.
Прогнозирование	Ретроспективные числа подтверждены. Восемь конфигураций без Chronos повторно обучены с точным совпадением. Устойчивое преимущество выбранного Prophet и качество на свежем финальном тесте не доказаны.
Изменения / шоки	Последовательность вычисления статистик подтверждена. 108 первых метод-территория тревог воспроизведены. Это кандидаты, не 108 доказанных шоков. Ранний экономический сигнал не валидирован.
Воспроизводимость	Численный путь воспроизведён в подготовленном окружении; coqe-инструкция неполна; Chronos не перезапущен; настоящий браузер не прошёл запуск. Независимые исходные данные доступности и событий отсутствуют.

Комплект годится как честное ретроспективное исследование с ограничениями. До подачи следует унифицировать приложения, завершить обязательную форму кода и исправить воспроизводимость. Нельзя подавать подтверждённые исторические ошибки как доказательство будущего преимущества или раннего предсказания экономических шоков.

Что именно выполнено

Независимо пересчитаны 218 835 ошибок девяти конфигураций на 24 315 общих целей для каждой; 36 строк метрик совпали с сайтом без численного расхождения. Повторный расчёт восьми конфигураций без Chronos совпал в 194 520 целевых прогнозах. Воспроизведены остатки, детекторы, stress/bootstrap и сравнение с новостями: 14 типов файлов, максимальная численная разница 0. Авторские проверки: 13 + 19; DOM сайта: 3554.

Отдельно повторён predict.py для всех 2075 МО с cutoff2024-12: 8300 точечных прогнозов на 2025-01/03/06/12 совпали с latest_forecast.csv, максимальная разница 0 руб. Факты 2025 не предоставлены; качество экспортов не оценено. Новые issued_at отражают время аудита 2026, не выдачу прогноза в 2024. Сверка: latest_forecast_comparison.json.

Архив содержит report/Validation_Report_RU.pdf и .md; results/ - пересчитанные таблицы; evidence/ - журналы, тексты и официальный PDF; validate_bundle.py, compare_replays.py, finish_checks.py и extract_inputs.py - код проверки; fixes/asof.py - изолированное предложение. README описывает границы воспроизведения.

1. Официальное задание и требования

Официальная страница получена отдельно от материалов проекта. Положение скачано с sber.ru 05.10.2026 и совпало побайтово по SHA-256 с docs/Official_Contest_Rules.pdf: 2afee8b042ac0f16baa420a79a10663929a92950cd1b2c6f80a079088c71d0d3. Сохранены HTML, PDF и извлечённый текст. Веб-парсер не смог открыть URL; документ получен отдельным HTTP-запросом. Требования не восстанавливались из предположений.

Источники: https://sber.ru/sberindex/konkurs_sberindex и https://sber.ru/common/assets/sber/sberindex_polozhenie_o_konkurse.pdf. Цель: прогноз потребления муниципалитетов и раннее выявление возможных будущих шоков. Обязательны минимум один датасет СберИндекса, MAE, горизонты 1/3/6/12 и установленный состав подачи. R^2 опционален. Новости и фундаментальные модели оцениваются, однако фундаментальная модель обозначена дополнительным преимуществом.

Критерий §6.2	Вес
Понятность методологии	10%
Сравнение прогнозов	20%
Сравнение детекторов	20%
Фундаментальные модели	15%
Интеграция новостей	15%
Метрики, MAE обязательна	10%
Интерпретация / воспроизводимость	10%

Страница формулирует цель превзойти базовую модель, но §6.2 и приложение 2 допускают обоснованный результат в пользу Prophet. Отсутствие победы над ним не объявляется автоматическим формальным нарушением. Официальные документы не задают универсальную допустимую MAE, веса территорий, event-tolerance, FPR=5% или proху=20%. Эти значения - решения исследователя, не условия конкурса. Фиксированный исходный датасет документирован за январь 2023 - декабрь 2024; дополнительных обязательных тестовых дат не обнаружено.

По §3 требуется GitHub с инструкцией и конфигурациями, русский методологический отчёт и PDF-презентация либо интерактивный лендинг с архитектурой, сравнениями и реальными случаями. PPTX сам по себе не заменяет PDF; нужный PDF есть в исправленном архиве сайта. Неопубликованный лендинг не является дефектом локального этапа: для допустимой PDF-поддачи публикация сайта не обязательна. GitHub остаётся обязательным.

Ниже таблица фиксирует наблюдаемое выполнение. Статусы «подтверждено» относятся ровно к описанному свойству, а не к общему успеху. «Не проверено» означает недостаток данных или незавершённое испытание; «не применимо» - свойство не заявлено.

2. Требование → реализация → доказательство → статус

Требование	Реализация / доказательство	Статус
Минимум один датасет СберИндекса	consumption.parquet, целевая категория «Все категории»; data/raw/data_license.txt; src/prepare.py; results/data.json	подтверждено
Прогноз потребления в МО и сравнение моделей	Девять конфигураций, единые цели; rolling-origin; configs/experiment.yaml; metrics_by_horizon.csv; replay_comparison.csv	подтверждено
Горизонты 1, 3, 6, 12 месяцев	Прогноз ровно t+h, не сумма за h месяцев; validate_bundle.py; 36 строк метрик; 4/4/3/1 origins	подтверждено
MAE обязательна, R ² опционален	MAE, R ² , RMSE, WAPE; числа пересчитаны; metrics_by_horizon.csv; максимальное расхождение 0	подтверждено
Сравнение детекторов и обоснование выбора	CUSUM, Page-Hinkley, EWMA, Shewhart; синтетика и стресс; synthetic_metrics.csv; detector_stress_grid.csv; повторный запуск detect.py	подтверждено
Раннее выявление будущих шоков	Есть проху будущего годового изменения; независимых шоков нет; direction_warning_metrics.csv; пустой шаблон событий; published_at неизвестен	не проверено
Современная фундаментальная модель	Chronos-Bolt Tiny включён; метрики сохранённых прогнозов проверены; foundation_model.json; forecasts/metrics; новое inference не выполнено	подтверждено
Новости и корректное согласование для обеих задач	17 сообщений ЦБ, 4 признака; абляция прогноза и детектора; src/prepare.py; src/news_detector.py; news_detector_ablation.csv	подтверждено
Полезность новостей для результата	Ridge с новостями хуже; муниципальный эффект не установлен; MAE 6286,81 → 18929,35 руб.; нет независимых событий	не проверено
GitHub-репозиторий исходников	Репозиторий ещё не опубликован; имеется локальный ZIP; README.md; index.html #repository-status	нарушено
Инструкция и YAML/JSON	Файлы присутствуют; в core отсутствует reportlab для make validation; README.md; requirements-core.txt; Makefile; build_validation_materials.py:11	нарушено
Методологический отчёт на русском	Есть исправленный PDF; отдельное приложение - прежняя версия; site_report.txt (12 стр.); attached_report.txt (9 стр.)	подтверждено
PDF-презентация или интерактивный лендинг, архитектура и реальные случаи	В сайте есть PDF-презентация и лендинг; отдельный PPTX иной версии; dist/downloads; site_slides.txt; case_319/322_baselines.csv	подтверждено
Согласованность всех представленных результатов	Отдельные приложения: 8 сигналов; сайт и проект: 108; attached_report.txt:240; site_report.txt:16; detect_replay.log	нарушено
Анонимный доступ по внешним ссылкам	Сайт намеренно не опубликован; публикация в аудит не входила; Локальный архив; внешняя производственная проверка отсутствует	не проверено

2а. Дополнительные проверки качества

Это рекомендации независимого аудитора. Они не представлены как самостоятельные обязательные правила конкурса. Полная машинно-читаемая таблица с основаниями находится в `results/requirements_matrix.csv`.

Проверка	Реализация / доказательство	Статус
Настоящая доступность расходов на дату прогноза	Снимок скачан в 2026; реальных <code>published_at/vintages</code> нет; <code>data_availability.json</code> ; <code>temporal_registry.parquet</code>	не проверено
Правильный выбор последней доступной версии	<code>asof.py</code> выбирает последнее скачивание; старое вытесняет новое; <code>asof_counterexample.json</code> ; <code>asof_fix_test.json</code>	нарушено
Справочник МО, коды и стабильность границ	Источник заявляет постоянные границы; независимой сверки нет; <code>data_license.txt</code> ; <code>data_availability.json</code> ; справочник не восстановлен	не проверено
Отсутствие будущего в вычислениях	Сдвиги/ <code>ffill/scaler</code> в прошлом; <code>prefix/mutation</code> тесты прошли; <code>future_mutation_checks.csv</code> ; <code>verify*.log</code> ; <code>validate_bundle.py</code>	подтверждено
Финальный тест, не использованный при разработке	2024 уже просмотрен; новый <code>prospective</code> опыт не выполнен; <code>README.md</code> ; <code>configs/prospective_lock.json</code> ; шаблоны без будущих фактов	не проверено
Покрытие и ширина прогнозных интервалов	Публикуются точечные прогнозы; <code>uncertainty_samples=0</code> ; <code>src/forecast.py:99</code> ; <code>default_baseline.py:26</code>	не применимо
Прогноз для новых муниципалитетов	Такой сценарий не заявлен и не реализован; нужны 12 месяцев истории; <code>minimum_history=12</code> ; выборка полная в 2023	не применимо
Техническая логика и локальные ссылки сайта	3554 DOM-проверки прошли; SVG конечны при четырёх ширинах; <code>evidence/site_dom.log</code> ; <code>qa/verify-site.mjs</code>	подтверждено
Внешний вид сайта в настоящем браузере	Chromium завершился <code>SIGTRAP / exit 133</code> ; DOM не заменяет браузер; Нативная браузерная проверка не завершена	не проверено

3. Данные, цель и доступность

Файл data/raw/consumption.parquet содержит 303 126 записей, 2190 исходных ID, шесть категорий и 24 месячные даты 2023-01...2024-12. Выбрана «Все категории». На входе кода значение называется value, тогда как описание называется consumption; это явно отражено в аудите. Цель - оценка средних месячных безналичных расходов жителей МО в рублях, построенная моделями СберИндекса на транзакционных данных. Это не суммарный муниципальный оборот и не прямое полное измерение потребления.

Проверка	Результат
Ключ date x territory_id x category	Дубликатов нет; pivot и панель восстановлены независимо и совпали
Хронология	24 последовательных месяца; пропуски значений не равны отсутствию месяца в календаре
Выборка	2075 МО с полным 2023 годом; 115 исключены только по прошлой истории
Пропуски 2024	575 ячеек у 59 выбранных МО; причины не маркированы
Нули / отрицательные / NaN в исходных строках	0 / 0 / 0; отсутствующие записи после pivot становятся NaN
Охват теста	2032 различных МО; на h6 - 2030, на h12 - 2023
Диапазон целевой панели	11 772...91 003 руб.; значения положительны

Нули, скрытые значения и истинное отсутствие не различаются источником на уровне пропущенных строк. Код не заменяет пропущенный факт нулём: обучение заполняется только прошлым, неизвестные тестовые факты исключаются одинаково для всех моделей. Но готовность модели к MNAR-пропускам и причинам скрытия не доказана. Отбор по полному 2023 смещает охват к более хорошо измеренным территориям.

Источник описывает ID как МО в постоянных границах. Справочник названий/ОКТМО не восстановлен; независимая проверка географии, объединений и смены методики не проведена. Сопоставимость постоянных границ документирована источником, но не проверена по геометрии. Реальные случаи потому подписаны ID, без выдуманных муниципальных названий.

Расходы номинальные: дефлятор не используется. На горизонтах до двух лет инфляция может объяснять годовой рост и проху. Weekly/daily сезонность Prophet выключена; «auto» годовая сезонность при истории менее двух лет не активируется; отдельный сезонный Prophet принудительно включает 3 гармоники. Календари праздников, число рабочих дней, погода и дополнительные данные Росстата не включены. Требование их обязательного применения не обнаружено.

Сырой parquet проверен по хешу и по построению панели. Хеш скачанного исходного ZIP (a9f932...b010) есть в manifest проекта, но сам ZIP источника в полном архиве отсутствует и заново не скачивался в этом аудите. Независимая сверка source ZIP → parquet поэтому не выполнена. Оригинальный parquet SHA-256: 9833ddaaee7b2a182ed4cceed16469031700ea87d508bd976150c6770ef8a61.

Дата наблюдения не является датой знания

Проект сохраняет retrieved_at=2026-10-03 с точностью до дня и vintage снимка. Для всех реальных расходов published_at неизвестен; прошлых версий и календаря пересмотров нет. Следовательно, запуск на «декабрьской истории 2023» не доказывает, что её последние значения были известны 31.12.2023. Анализ лага 1 месяц - сценарий чувствительности, не установленный календарь публикации. Новые asof/prospective модули и пустые шаблоны не заменяют фактический реестр и новый опыт.

4. Как строится прогноз и проверялись утечки

У каждой территории есть собственный месячный ряд. На `origin` код берёт только историю до этой даты; пропуски переносит вперёд из прошлого; повторно обучает модели. Прогноз рассчитывается на каждый будущий месяц до 12, но оцениваются ровно месяцы $t+1$, $t+3$, $t+6$, $t+12$. Объединение муниципалитетов применяется в Ridge; Prophet обучается отдельно для каждого ID.

Метод	Математический механизм / информация
Prophet	$y(t)=g(t)+s(t)+\epsilon$. Кусочно-линейный тренд; MAP-оценка с нормальной ошибкой и Laplace-приором на изменения наклона. В данной короткой истории основной вариант практически прогнозирует тренд. 5 точек, <code>changepoint_prior_scale=.05</code> ; фактических будущих расходов не получает.
Ridge	Линейная регрессия с L2-штрафом. Логарифмы относительно первых 6 месяцев; лаги 1/2/3/6, среднее/стандартное отклонение/тренд, $\sin/\cos$ месяца. <code>StandardScaler</code> fit внутри истории. Рекурсивный шаг лог-прироста ограничен $\pm.25$; внешние новости заморожены на <code>origin</code> .
Затухающий тренд	OLS наклона $\log(y)$ последних 6 месяцев; предел $\pm.03$ /месяц; будущий наклон затухает с $.85$. Это простой статистический baseline.
Наивные	Последний известный уровень; уровень того же месяца прошлого года. Одинаковые цели и доступная история.
Chronos-Bolt	Предобученная модель, zero-shot по историческому ряду, квантиль $.5$; revision и веса по хешам сохранены. Ни экономической причинности, ни индивидуальных новостей этот вариант не моделирует.

Ключевые места: `src/forecast.py:20` (`past_fill`), :56 (Prophet), :115 (признаки), :138 (Ridge), :224 (`origin`-петля); `src/default_baseline.py:16`. Случайного разбиения временного ряда, централизованного сглаживания, `backfill` будущими значениями и `scaler` по всей истории не обнаружено. Это вывод из кода и конкретных `mutation`-тестов, а не доказательство отсутствия любого потенциального канала утечки.

Эмпирически: для Ridge с/без новостей проверены все 2075 МО $\times$ 4 origins; будущие расходы заменены 10^9 и будущие новости 10^6 . Прогнозы не изменились. Для двух Prophet-конфигураций - 12 фиксированных МО $\times$ 4 origins; также точное совпадение. Для четырёх детекторов изменялись будущие инновации после каждого из 12 префиксов по всем территориям; прошлые статистики инвариантны. Chronos таким тестом не проверен. Исследовательские параметры зафиксированы в YAML, но публичное предшествующее тесту время их фиксации не доказано.

Обнаруженная проблема находится в `src/asof.py:70`: сортировка по `retrieved_at` выбирает последнее скачивание, а не последнюю опубликованную ревизию. `v1=100` опубликована 01.02, скачана 01.04; `v2=200` опубликована 01.03, скачана 02.03; на 02.04 код выбирает 100. Это воспроизведённый дефект выбора версии, не доказанная утечка в уже рассчитанных исторических MAE: исходный `backtest` не вызывает `asof.py`.

Изолированная копия `fixes/asof.py` возвращает 200, сохраняет инвариантность к недоступной будущей `v3` и отклоняет неоднозначный порядок ревизий. Предпосылка исправления: `published_at` относится к конкретной ревизии; если источник оставляет старую дату, нужны `revised_at` или `revision_seq`. Исторические прогнозы не заменялись; `lock` исходного проекта не перезаписывался.

Другие ограничения: 2024 уже использовался для анализа и исправлений - это адаптация протокола к увиденному тесту. Chronos-Bolt выпущен 26.11.2024, позже всех origins; это современный ретроспективный benchmark, не исторически исполнимая стратегия. Источник даты - официальный README `amazon-science/chronos-forecasting`. Пересечение pretraining с тестом не установлено и не объявляется доказанной утечкой.

5. Протокол и пересчитанные метрики

Протокол аудита: сохранить девять исходных конфигураций и общие тестовые цели, не менять гиперпараметры по результатам; переобучить доступные классические модели; независимо пересчитать ошибки. Origins: 2023-12, 2024-03, 2024-06, 2024-09. Обучение расширяется; неизвестный тестовый факт пропускается для всех. Параметры не подбирались в аудите. Свежий финальный test отсутствует; оценка исключительно ретроспективная.

h, мес.	Origins	Тестовых пар	МО
1	4	8111	2032
3	4	8106	2032
6	3	6075	2030
12	1	2023	2023


$MAE = (1/N) \sum |\hat{y} - y|$; $RMSE = \sqrt{[(1/N) \sum (\hat{y} - y)^2]}$; $R^2 = 1 - \frac{\sum (\hat{y} - y)^2}{\sum (y - \text{mean}(y))^2}$; $WAPE = 100 \frac{\sum |\hat{y} - y|}{\sum |y|}$. Основные строки имеют равный вес доступных пар ID-origin-target, не строго равный вес всех МО. Отдельно $\text{mean}_i(MAE_i)$ даёт равные территориальные веса. Полного оборота/населения для экономических весов нет; придумывать такие веса нельзя.

$MASE(\text{лаг } 1) = \text{mean}_i[MAE_i / \text{mean}_{\{t \in 2023\}} |y_{i,t} - y_{i,t-1}|]$. Это несезонная нормировка, не сравнение с сезонным наивным на тесте. Сезонный масштаб lag12 нельзя устойчиво оценить по одному 2023 году. Нулевой/неизвестный масштаб исключается с отдельным счётчиком; здесь их 0. При нулевых знаменателях WAPE/R² результат должен быть неопределённым; в общем тесте нулей нет. MAPE не используется как главный критерий; сохранённый mean APE допустим для положительной панели, но не переносится на ряды с нулями.

Модель	MAE h1	h3	h6	h12
Prophet, 5 точек	1 884,46	2 261,91	2 757,70	2 904,23
Prophet default	1 884,43	2 262,22	2 758,15	2 905,80
Последнее значение	2 620,04	2 858,84	2 962,16	4 700,73
Сезонный наивный	4 015,64	4 257,17	4 415,69	4 700,73
Затухающий тренд	2 743,92	3 736,16	3 234,20	1 734,04
Prophet, годовая сезонность	3 452,26	3 719,42	4 574,26	8 330,27
Ridge	4 717,48	6 616,12	6 398,75	10 923,13
Ridge + новости	5 327,79	16 827,39	39 338,70	20 597,25
Chronos-Bolt Tiny	2 653,96	3 350,12	4 727,92	10 743,06

Рубли, меньшая MAE лучше. Все исходные результаты сохранены; отрицательные результаты Ridge/Chronos не скрыты. Prophet default отличается по настройкам точек/сезонности, но практически даёт те же ошибки. Точечные прогнозы имеют нижнее ограничение 1 руб. Никакого универсального порога «успешности» аудит не назначает.

5а. Сравнение по горизонту и уровню расходов



На общих целях Prophet имеет меньшую MAE на 1/3/6 месяцев, чем наивные прогнозы и выбранные Ridge/Chronos. На 12 месяцах простой затухающий тренд лучше. Это наблюдаемая сравнительная таблица, а не правило будущего выбора: модель по горизонту нужно выбирать на прошлой валидации и проверять на свежем тесте.


Prophet: квартиль среднего уровня расходов 2023 года

Группа	MAE h1	h3	h6	h12
Q1	1 312,30	1 664,91	1 754,79	2 989,36
Q2	1 525,36	1 929,16	2 120,56	3 373,71
Q3	1 750,47	2 241,29	2 762,22	2 902,50
Q4	2 920,04	3 185,19	4 347,74	2 361,16

Группы определены средними номинальными расходами в 2023: Q1 - меньший уровень, Q4 - больший. Это не административные или социально-экономические типы. Квартильные границы задаёт исходный `selection.csv`; для всех моделей используются те же группы и доступные цели. Разница MAE в рублях частично связана с разным уровнем расходов; WAPE и MASE приведены отдельно, чтобы не скрывать масштаб.

Подробные числа по каждому муниципальному ID доступны в `metrics_by_territory.csv.gz`. Общая средняя не устанавливает приемлемость для любого отдельного ID; на h6 около трети территорий хуже простого `last_value`, несмотря на более низкую агрегированную MAE Prophet.

6. Не скрывает ли среднее слабые результаты



На h1 Prophet уступает последнему значению в апреле (893,74 против 790,18 руб.) и июле (1150,50 против 990,09). Большая часть агрегированного преимущества связана с январским падением после декабря. Четыре времени проверки нельзя считать тысячами независимых временных экспериментов только из-за числа территорий.

Показатель Prophet	h1	h3	h6	h12
RMSE, руб.	2 897,75	2 954,83	3 459,62	3 698,80
WAPE, %	6,36	7,05	8,46	7,86
Pooled R ²	0,932	0,939	0,921	0,923
Within-territory R ²	0,033	0,131	−0,013	не определён
MAE с равным весом МО, руб.	1 888,13	2 267,94	2 762,39	2 904,23
MASE(лаг1)	1,179	1,472	1,766	2,017
МО, где Prophet хуже baseline, %	8,56	12,45	32,56	73,90

В последней строке baseline - last_value на 1/3/6 и damped_trend на 12. Within R² вычислен с внутритерриториальным центром фактов теста; на h12 один факт на МО, поэтому знаменатель 0. Высокий pooled R² в основном отражает способность различать уровни территорий, а не точность изменения внутри каждого ряда. Положительная MAE/MASE при этом остаётся полезной, её не следует заменять красивым R².

Таблицы по каждому ID, origin, горизонту и квартилю среднего уровня 2023 находятся в results/. Ни географические группы, ни экономические типы территории без справочника не выдуманы. На проху-изменениях 20% (2 из 3 будущих месяцев год-к-году) Prophet MAE h1=1947,86 против 1866,06 без проху; h3=1911,58 против 2333,37. Эти условные группы не являются независимой разметкой шоков. Сравнение новых МО не заявлено; каждый тестируемый МО присутствует в обучении.

Воспроизведён кластерный bootstrap2000, seed20261004, с повторным выбором территорий и origins. Для Prophet-last h1:−735,58 руб., условный 95% интервал[−1926,11;140,30]; h3:[−2103,93;514,71]; h6:[−1695,08;652,31]. Ноль внутри; при 3–4 временных кластерах интервалы лишь описательные. Для h12 один origin - временная неопределённость не оценивается. Эти интервалы не являются прогнозными интервалами для расходов.

Прогнозные интервалы не публикуются: uncertainty_samples=0. Покрытие и ширина поэтому не проверяются и не считаются нарушением отдельного официального требования. Варьирование seed/окна/набора признаков не даёт полного исследования устойчивости; есть default/seasonality/news/лаг 1 и synthetic-stress, но нет нового независимого опыта.

7. Структурные изменения: что действительно измерено

Задача	Что реализовано	Доказательность
Предсказать ещё не начавшееся изменение	Форвардный проху из прогнозов: 2 из 3 месяцев годового изменения одного направления	Корректно пересчитан, но не размеченные экономические шоки
Обнаружить начавшееся отклонение	CUSUM/PH/EWMA/Shewhart на ошибке одномесячного Ridge после поступления нового факта	Префиксный алгоритм подтверждён; реальное календарное время выдачи неизвестно
Ретроспективная точка разрыва	Prophet changepoints внутри обучения; отметки статистики в месяце наблюдения	Не дата экономического начала и не доказательство опережения

Инновация - $\log(\text{actual} / \text{forecast})$, центр и MAD определяются по пяти past-ошибкам августа-декабря 2023, с общим нижним порогом масштаба. Пропущенный факт не обновляет состояния. Детектор видит фактическое отклонение, поэтому тревога - после получения нового значения, не автоматически до события. Поле date соответствует месяцу наблюдения; настоящего issued_at/published_at нет. Истинная change_onset также не установлена.


CUSUM накапливает направленные остатки с drift .5; Page-Hinkley сравнивает накопление со своим прошлым минимумом, reference_count12 и drift .25; EWMA $\alpha=.3$ сглаживает остаток; Shewhart пороугет $|z|$. Реальный мониторинг -12 месяцев, отдельные пороги; исходная синтетика -48 наблюдений после 12warmup. Их нельзя смешивать как одинаковую задачу. Подсчёт реальных тревог ограничен первым сигналом для каждой пары метод-ID.

Метод	Реальные первые тревоги	Null-тест12м, %	Recall step2σ за12м, %	Медианная задержка, мес.
CUSUM	53	7,4	98,67	5
Page-Hinkley	43	6,8	96,00	5
EWMA	10	5,4	96,00	4
Shewhart	2	4,6	58,67	4

Итого 108 метод-ID сигналов у 54 различныхтерриторий. Recall/задержка справа - исходный 48-месячный синтетический протокол, не реальные события и не тот же 12-месячный мониторинг. Recall считает первый сигнал только в[24;36); тревога до 24 лишает ряд зачёта, повторные сигналы не спасают. Поздние обнаружения за пределами 12 месяцев считаются пропуском. Задержка дана только для успешных обнаружений, не для всех рядов. Шаг/тренд известны генератору; class mix синтетики не имитирует реальную частоту событий.

Ни реальные precision/recall/F1, ни задержка от экономического onset не вычислены: нет независимой разметки. Кандидаты в реальных рядах допустимы как case studies с альтернативами, а не ground truth. Межтерриториальная множественность означает, что калибровочная цель 5% на один ряд не ограничивает число ложных тревог на 2075 МО и 4 метода.

8. Чувствительность детекторов, проху и новости



Пороги калиброваны на $AR(1) \phi = .3$. На независимых null-сериях без пропусков при $\phi = .6$ доля рядов хотя бы с тревогой: CUSUM 24,6%, PH 28,8%, EWMA 21%, Shewhart 2,2%. При $\phi = .0$ - 0,2/0,6/0,4/3,2%. Порог 0,8/1/1,2, изменения 5/1/2 σ , пропуски 0/10%, сезонность и выбросы воспроизведены в 432 строках stress-grid. Это проверка зависимости от шума, не универсальная оценка реального FPR.

Shewhart служит простой контрольной моделью. На исходном протоколе одиночный 5-выброс вызывает тревогу у 95,33% рядов Shewhart и 9,33/19,33/42% CUSUM/PH/EWMA. Следовательно, без подтверждающей устойчивости многие методы не отличают выброс от структурного изменения. Сравнение при одинаковой цели калибровки 5% проведено; фактические FPR различаются. Равный эмпирический FPR на нескольких шумах не установлен.

Прогу-порог годового изменения	Положительных из 8096	Precision Prophet	Recall	F1
10%	6596	0,881	0,888	0,884
20%	1372	0,395	0,620	0,483
30%	50	0,037	0,480	0,069

Для 20%: TP851, FP1302, FN521. Знак учитывается: неверное направление считается FP и FN; macro_tightening_flag исключён, потому что направление не предсказывает. Указанный 20% порог - авторский проху, не официальный и не экономически универсальный. Инфляция, низкая база, сезонность и изменение измерения влияют на него. Пары origin могут перекрываться и зависеть по территориям.

17 датированных пресс-релизов ЦБ дают ключевую ставку, изменения ставки за 3 месяца и 2 словарных флага. Признаки известны по датам публикации; будущие значения не подставляются, до конца прогноза используются последнее известное состояние. Это 17 общих макрообобщений, а не тысячи независимых локальных новостей. Повторная проверка 17 страниц описана в сохранённом source_recheck.json; в этом аудите онлайн-получение текстов ЦБ не повторялось.

Абляция даёт MAE Ridge 6286,81 → Ridge+news 18929,35 руб. (+201,1%). Для детекторов без/с новостями: CUSUM 53/44, PH 43/22, EWMA 10/167, Shewhart 2/1759. Эти количества полностью воспроизведены при одинаковых порогах и протоколе; без разметки это не precision. Резкое увеличение Shewhart-кандидатов свидетельствует о нестабильной остаточной модели, не о 1759 новых подтверждённых шоках.

9. Экономическая интерпретация и согласованность подачи

Наблюдение → модель	Допустимая интерпретация	Альтернативы / ограничения
ID322: июнь2024=51459руб.; Ridge31443,30; last40374; Prophet42350,46	Расходы выше разных прогнозов; относительное отклонение63,66/27,46/21,51%	Сезонный/календарный паттерн, инфляция, база/состав карт, ошибка Ridge. Нет внешнего onset/географического имени/даты выдачи.
ID319: заметное увеличение июня-июля; остаточный детектор реагирует	Кандидат на проверку изменения локального ряда	Номинальное и модельное измерение; источник изменений не установлен. Даты ЦБ не доказывают причинность.
Январь2024 хуже прошлого декабря для last_value	Перенос декабряского уровня плохо учитывает регулярный спад	Это общий календарный эффект, не доказательство локального экономического шока.
Большие тревоги в news-Shewhart	Новостной Ridge изменил качество остатков	Может быть промахом прогноза/масштаба; причинный эффект ставки и муниципальная чувствительность не идентифицированы.

Два реальных случая являются демонстрациями, выбранными после анализа; это не репрезентативная оценка событий. Модель детектора в них - Ridge независимо от выбранной линии прогнозного сравнения, что обновлённый сайт поясняет. Точку пересечения порога нельзя переименовывать в момент экономического шока.

Версии

Отдельно приложенный отчёт имеет 9 страниц, презентация 15 слайдов. В ZIP сайта исправленный отчёт имеет 12 страниц, презентация 14 слайдов и PDF-копию. Старый отчёт указывает 8 первых сигналов для 4 МО и отсутствие PH-сигналов; обновлённый -108 для 54 МО, исправляет missing-state/PH/calibration и добавляет Shewhart. Forecast MAE совпадают в обеих версиях, но detector и проху-оценки относятся к разным протоколам. Старое утверждение о равных весах территорий также неточно: равны доступные тестовые пары.

Рекомендация: принять версию от 04.10 как текущую; пересобрать отдельные приложения из неё, включить version/commit/input hashes. Старые документы оставить только с маркировкой «архивный протокол, не итоговая подача». Внутренние файлы src/config из сайта совпадают с научным архивом; встроенные 36 строкметриков совпадают с results.json и пересчётом.

Визуальная и техническая проверка

Все страницы двух отчётов и двух презентаций визуально просмотрены после рендеринга: существенной обрезки/наложений не обнаружено, таблицы и подписи читаемы. Отдельный PPTX преобразован через LibreOffice; это проверка предоставленного документа, а не факт совпадения со старым отсутствующим PDF.

3554 проверки сайта через DOM проверили 12 комбинаций горизонт-метрика, 9 моделей, 2 случая, 3 базовых линии, 4 детектора, 12 месяцев и 4 заданные ширины; локальные ссылки и конечность SVG. Настоящий Chromium не запустился (SIGTRAP/exit133). Поэтому пиксельная адаптивность, настоящие keyboard/clipboard и внешняя анонимная доступность остаются непроверенными. Публикация/авторизация/рассылка в этот аудит не входили.

10. Проблемы по приоритету: критические

К1. Историческая доступность не подтверждена

Доказательство: Все published_at расходов неизвестны; снимок от 2026-10-03.

Последствия: Оценка не доказывает результаты реально доступной стратегии в 2024.

Исправление: Вести датированные версии; формировать as-of на дату выдачи; задержку задать по реальному календарю; провести новый опыт.

К2. Нет независимой истины о реальных шоках

Доказательство: 108 тревог на остатках; гроху - годовой рост, независимый реестр пуст.

Последствия: Нельзя утверждать раннее предсказание или точность обнаружения экономических шоков.

Исправление: Независимый полный реестр onset/publication/direction; заранее tolerance/refractory/lead-window; последовательный replay по публикациям.

К3. Комплект содержит разные версии результатов

Доказательство: Отдельные PDF/PPTX: 8 сигналов / 4 территории; сайт:108 /54.

Последствия: Эксперт получает противоречивые результаты и методики.

Исправление: Выбрать исправленную версию от 04.10; пересобрать все приложения из одного manifest; старую маркировать архивной.

К4. Нет обязательного GitHub-репозитория

Доказательство: README и лендинг прямо указывают отсутствие.

Последствия: Локальный архив не выполняет требование к форме подачи кода.

Исправление: Опубликовать после исправлений репозиторий; проверить доступ без входа; закрепить commit/tag и инструкцию.

Приоритеты относятся к доказательности заявленных целей и готовности подачи. Они не являются конкурсной системой баллов; итоговый балл жюри аудит не подменяет. Честное указание недостатка в исправленном отчёте снижает риск вводящей в заблуждение подачи, но не восполняет недостающие факты.

10а. Существенные проблемы

C1. Короткая и уже просмотренная проверка

Доказательство: 4/4/3/1 origins, 24 месяца; последний 2024 не независим. Последствия: Не доказаны стабильность победы, итоговая годовая ошибка и перенос на новые периоды.

Исправление: Заморозить протокол; собрать новые месяцы/доступные версии; вложенная валидация только внутри прошлых периодов.

C2. Не доказано преимущество выбранного Prophet

Доказательство: Почти совпадает с default; h12: 2904 против 1734 у тренда. Последствия: Нельзя назвать одну модель лучшей на всех горизонтах.

Исправление: Заявлять сравнительный исследовательский результат; выбор по горизонту подтвердить на свежих периодах.

C3. Ошибки baseline превращаются в кандидаты изменений

Доказательство: Ridge слабый; масштаб из 5 ошибок; null AR(.6):CUSUM24.6%,PH28.8%.

Последствия: Тревоги могут отражать сезонность/шум/неадекватный прогноз вместо изменения экономики.

Исправление: Длиннее past-only калибровка; проверить остатки/пропуски; сопоставить детекторы при равной эмпирической частоте ложных тревог; бюджет тревог по панели.

C4. Неверный выбор версии в asof.py

Доказательство: Сортировка retrieved_at: v1=100 вытесняет более новую опубликованную v2=200.

Последствия: Будущая as-of оценка может использовать устаревшее значение; текущие MAE этим дефектом не пересчитывались.

Исправление: Сортировать по времени публикации конкретной ревизии или явному revision_seq; retrieval использовать как фильтр доступности; неоднозначность отклонять.

C5. Неполный набор core-зависимостей

Доказательство: reportlab отсутствует в core, но builder импортирует его в make validation.

Последствия: Инструкция не обеспечивает сборку PDF на чистой установке.

Исправление: Добавить reportlab==4.4.9 и нужные прямые зависимости; разделить numeric/report цели; проверить контейнер с чистой установкой.

106. Остальные ограничения и исправления

С6 (существенная). Фундаментальная модель не полностью перепроверена

Доказательство: Chronos inference не запущено; релиз 26.11.2024 позже origins; pin после первого опыта. Последствия: Подтверждены сохранённые ошибки, не весь цикл inference и не историческая применимость.

Исправление: Новый запуск с revision/hash и журналом; пометить современный ретроспективный benchmark; проверить возможное пересечение pretraining.

С7 (существенная). Полезность новостей не доказана

Доказательство: MAE Ridge +201.1%; Shewhart1759 кандидатов; всего 17 общих сообщений. Последствия: Нет улучшения качества и нет локальной/причинной интерпретации.

Исправление: Сохранить отрицательный результат; больше датированных региональных публикаций; оценка на независимых событиях и прошлой калибровке.

В1 (второстепенная). Отсутствует цитируемый дополнительный отчёт

Доказательство: site_report ссылается на Validation_Report_RU(3).pdf, которого нет в комплекте. Последствия: Некоторые ссылки на историю проверки непроверяемы.

Исправление: Приложить документ либо удалить ссылку и дать доступные доказательства.

В2 (второстепенная). Нет завершённой браузерной и внешней проверки

Доказательство: DOM3554passed; ChromiumSIGTRAP; сайт не опубликован. Последствия: Не подтверждены пиксельная адаптивность, реальный clipboard и внешний доступ.

Исправление: Перед подачей проверить desktop/mobile/keyboard/clipboard/downloads в работающем браузере; после публикации - анонимный доступ.

Чистая установка core зависимостей была предпринята отдельно и завершилась ненулевым кодом: pip сообщил несовпадение хеша скачанного unknown package. Это ограничение установки/доставки в текущем окружении, не доказательство дефекта опубликованной библиотеки или файла требований. Не обходились проверки хеша. Вывод о пропущенном reportlab основан на анализе прямого импорта и core-списка, а не на заявленном успешном clean-install.

11. Воспроизводимость, границы и недоказанные утверждения

Python3.12.14; numpy2.3.5,pandas2.2.3,pyarrow25.0.1,sklearn1.8.0,scipy1.17.0,Prophet1.4.0,cmdstanpy1.3.0,holidays0.105,PyYAML6.0.3,matplotlib3.10.8. PDF:reportlab4.4.9. В native окружение добавлены только необходимые численные пакеты. Архив включает environment.json и отдельные журналы. Научные seed:20261003; detector calibration20261003,test20261004; bootstrap20261004;stress20261005. ПотокиBLAS/OMP=1; CPU, безChronos/PyTorch.

Код audit не выбирает модели/пороги по полученной ошибке. Исходные модели оценены до isolatedfix. prepare.py по сети заново не исполнялся; raw→panel восстановлен независимым кодом из предоставленного parquet. forecast/default/detect/news_detector повторно запущены в копии; forecastsChronos сохранены и метрики проверены без inference. diagnostics/future_warning повторены на исходных сохранённых полных прогнозах, что прямо отражено в README. Новый prospective результат не создавался.

Команды: python validation_20261005/extract_inputs.py; python validation_20261005/validate_bundle.py; в project_replay: python src/forecast.py --skip-chronos --workers 6; python src/default_baseline.py; python src/detect.py --config configs/validation.yaml; python src/news_detector.py; затем compare_replays.py сохраняет переобученные outputs отдельно и возвращает полный архивный набор прогнозов для diagnostics/future_warning; python finish_checks.py; node qa/verify-site.mjs с linkedom. Точные команды, зависимости и портируемый orchestration приведены в README и reproduce.py. Для node QA версия linkedom фиксируется в локальном package-lock.json.

Пока нельзя считать доказанными

- Выбранная конфигурация устойчиво превосходит Prophet default или все baseline на каждом горизонте.
- Годовая ошибка 2904 руб. и преимущество/недостаток тренда сохраняются на новых годах: h12 имеет только одну дату.
- Модель выдаёт ранние сигналы экономических шоков до их начала, с известным временем выдачи и доступными тогда данными.
- 108 реальных тревог соответствуют 108 экономическим шокам; нет независимых precision/recall/задержки для реальных событий.
- Новости улучшают муниципальный прогноз/детекцию или идентифицируют причинный эффект политики ЦБ.
- Исторические vintages, изменения измерения, причины пропусков и территориальный справочник проверены полностью.
- Chronos полностью перезапущен в этом аудите и не имеет пересечения pretraining с тестовой выборкой.
- Прогнозные интервалы откалиброваны; модель проверена на новых муниципалитетах; свежий финальный тест уже проведён.
- Сайт проверен в настоящем браузере, опубликован и доступен анонимно; GitHub удовлетворяет форме подачи.

Защитимые выводы: опубликованные исторические MAE и числа исправленных детекторов воспроизводятся; сравнение охватывает требуемые горизонты; основные преобразования и статистики используют префикс истории; новостная ветвь в данном опыте ухудшает прогноз; экономическая природа тревог и будущее качество требуют дополнительных данных. Результат проверки достаточности доказательств не заменяет будущую оценку качества.

Контроль перед выпуском аудита: согласованы таблицы, числа и вердикт; текущие источники вложений совпали с input_hashes.json; все 124 архивных файла проекта неизменны; isolatedfix не включён в оригинальный lock. Доказательства - локальные пути внутри пакета, официальные URL и журналы выполненных команд. Заявления об отсутствующих испытаниях не превращены в успешные результаты.